ĐẠI HỌC KINH TẾ QUỐC DÂN
VIỆN ĐÀO TẠO TIÊN TIẾN, CHẤT LƯỢNG CAO VÀ POHE

BÁO CÁO GIỮA KỲ 2 (MID-TERM 2)

PHÂN TÍCH TOÀN DIỆN QUY TRÌNH XỬ LÝ DỮ LIỆU

Đề tài:
PROJECT 2. BANK MARKETING DATASET

Môn học: Khoa học dữ liệu trong kinh tế và kinh doanh

Giảng viên: Trần Đức Minh

Nhóm: 16

Thành viên:

1. Tạ Gia Hân - 11240676 (nhóm trưởng)
2. Thái Thị Yến Nhi - 11240783
3. Phạm Phương Thảo - 11241131
4. Nguyễn Minh Thu - 11240812
5. Đoàn Huy Hoàng - 11240812

MỤC LỤC

MỞ ĐẦU 2
CHƯƠNG 1. THU THẬP VÀ ĐÁNH GIÁ DỮ LIỆU BAN ĐẦU 3
1.1. Nguồn dữ liệu, cấu trúc và mục tiêu bài toán 3
1.2. Bảng mô tả thuộc tính 3
1.3. Kiểm tra hiện trạng: kiểu dữ liệu, giá trị khuyết thiếu và trùng lặp 4
CHƯƠNG 2. TIỀN XỬ LÝ VÀ LÀM SẠCH DỮ LIỆU 6
2.1. Kiểm tra sai định dạng và giá trị bất hợp lệ 6
2.2. Dữ liệu trùng lặp 6
2.3. Xử lý giá trị ẩn 'unknown' 6
2.4. Phát hiện và xử lý ngoại lệ (outliers) bằng phương pháp IQR 7
2.5. Mã hóa (encoding) và chuẩn hóa (scaling): giải trình kỹ thuật 7
CHƯƠNG 3. PHÂN TÍCH VÀ TRỰC QUAN HÓA 9
3.1. Giả thuyết cần kiểm định và tổng quan biến mục tiêu 9
3.2. Phân tích nhóm khách hàng (H1-H5) 10
3.3. Phân tích chiến dịch tiếp thị (H6-H10) 14
3.4. Tương quan và kiểm định thống kê 18
3.5. Bảng tổng hợp giả thuyết H1-H10 20
CHƯƠNG 4. ĐÁNH GIÁ TÁC ĐỘNG VÀ KHUYẾN NGHỊ 21
4.1. Các phát hiện nổi bật nhất 21
4.2. Giải pháp thực tế (Hành động → Căn cứ số liệu → Lợi ích kỳ vọng) 21
4.3. Giới hạn của tập dữ liệu 21
4.4. Hướng mở rộng 22
TÀI LIỆU THAM KHẢO 23

MỞ ĐẦU

Báo cáo này trình bày toàn bộ quy trình xử lý và phân tích dữ liệu của **Project 2: Bank Marketing Dataset** theo bốn giai đoạn: (1) thu thập và đánh giá dữ liệu ban đầu, (2) tiền xử lý và làm sạch dữ liệu, (3) phân tích và trực quan hóa, (4) đánh giá tác động và khuyến nghị.

Dữ liệu ghi lại các cuộc gọi tiếp thị của một ngân hàng nhằm mời khách hàng đăng ký tiền gửi kỳ hạn (biến mục tiêu `deposit`). Mục tiêu của nhóm là tìm ra nhóm khách hàng nào, vào thời điểm nào và với cách tiếp cận nào thì khả năng đăng ký cao hơn, từ đó đề xuất cách tiếp thị hiệu quả hơn.

Toàn bộ mã nguồn (notebook `.ipynb` chạy được từ đầu đến cuối bằng Run All), dữ liệu, hình và bảng được lưu tại GitHub (chế độ public):

Link GitHub: https://github.com/nahaaig/KHDL-Nhom16-PRJ2

Mọi con số trong báo cáo được lấy trực tiếp từ kết quả chạy notebook trên tệp `bank.csv` gốc (11.162 dòng × 17 cột).

CHƯƠNG 1. THU THẬP VÀ ĐÁNH GIÁ DỮ LIỆU BAN ĐẦU

1.1. Nguồn dữ liệu, cấu trúc và mục tiêu bài toán

- **Nguồn:** Kaggle - *Bank Marketing Dataset* (tác giả janiobachmann), một file duy nhất `bank.csv`. Dữ liệu ghi lại các cuộc gọi tiếp thị của một ngân hàng nhằm mời khách đăng ký **tiền gửi kỳ hạn**.
- **Cấu trúc:** mỗi dòng là một khách hàng được liên hệ; **11.162 dòng × 17 cột** (7 biến số, 10 biến phân loại).
- **Nhóm thuộc tính:** (1) thông tin khách hàng: `age, job, marital, education`; (2) tài chính: `default, balance, housing, loan`; (3) chiến dịch: `contact, day, month, duration, campaign, pdays, previous, poutcome`; (4) biến mục tiêu: `deposit`.
- **Mục tiêu bài toán:** tìm các yếu tố làm tăng khả năng khách đăng ký tiền gửi kỳ hạn (`deposit = yes`) để đề xuất cách tiếp thị hiệu quả hơn (gọi nhóm khách nào, vào tháng nào, gọi bao nhiêu lần).
- **Tính nhất quán giữa các file:** dữ liệu chỉ có **một bảng**, nên không cần gộp và không phát sinh khóa chính/khóa ngoại.

1.2. Bảng mô tả thuộc tính

Bảng 1.1. Ý nghĩa, kiểu dữ liệu và số giá trị khác nhau của 17 thuộc tính

Thuộc tính	Ý nghĩa	Kiểu dữ liệu	Số giá trị khác nhau
age	Tuổi khách hàng	int64	76
job	Nghề nghiệp	object	12
marital	Tình trạng hôn nhân	object	3
education	Trình độ học vấn	object	4
default	Có nợ xấu (vỡ nợ tín dụng) hay không	object	2
balance	Số dư tài khoản trung bình năm (euro, có thể âm)	int64	3.805
housing	Có vay mua nhà hay không	object	2
loan	Có vay cá nhân hay không	object	2
contact	Hình thức liên hệ (cellular, telephone, unknown)	object	3
day	Ngày trong tháng của lần liên hệ cuối	int64	31
month	Tháng của lần liên hệ cuối	object	12
duration	Thời lượng cuộc gọi cuối (giây), chỉ biết SAU cuộc gọi	int64	1.428
campaign	Số lần liên hệ khách trong chiến dịch này	int64	36
pdays	Số ngày từ lần liên hệ chiến dịch trước (-1 = chưa từng liên hệ)	int64	472
previous	Số lần liên hệ trước chiến dịch này	int64	34
poutcome	Kết quả chiến dịch trước (success, failure, other, unknown)	object	4

Thuộc tính	Ý nghĩa	Kiểu dữ liệu	Số giá trị khác nhau
deposit	BIẾN MỤC TIÊU: có đăng ký tiền gửi kỳ hạn không (yes/no)	object	2

1.3. Kiểm tra hiện trạng: kiểu dữ liệu, giá trị khuyết thiếu và trùng lặp

Notebook chạy `info()`, `describe()`, đếm giá trị NaN, đếm chuỗi `unknown` (thiếu dữ liệu trá hình) và kiểm tra dòng trùng lặp. Kết quả được tóm tắt ở Bảng 1.2.

Bảng 1.2. Giá trị khuyết thiếu (NaN) và giá trị ẩn 'unknown' theo từng cột

Cột	Kiểu dữ liệu	Null (NaN)	Null (%)	Số 'unknown'	'unknown' (%)
age	int64	0	0	0	0
job	object	0	0	70	0,63
marital	object	0	0	0	0
education	object	0	0	497	4,45
default	object	0	0	0	0
balance	int64	0	0	0	0
housing	object	0	0	0	0
loan	object	0	0	0	0
contact	object	0	0	2.346	21,02
day	int64	0	0	0	0
month	object	0	0	0	0
duration	int64	0	0	0	0
campaign	int64	0	0	0	0
pdays	int64	0	0	0	0
previous	int64	0	0	0	0
poutcome	object	0	0	8.326	74,59
deposit	object	0	0	0	0

Nhận xét Giai đoạn 1

- **Kích thước:** 11.162 dòng × 17 cột; không có giá trị NaN ở bất kỳ cột nào và không có dòng trùng lặp (0 dòng).
- **Thiếu trá hình:** `isnull()` báo 0 nhưng dữ liệu vẫn thiếu dưới dạng `unknown`: `poutcome` 8.326 dòng (74,59%), `contact` 2.346 dòng (21,02%), `education` 497 dòng (4,45%), `job` 70 dòng (0,63%).
- **Biến mục tiêu:** `no` 5.873 khách (52,62%), `yes` 5.289 khách (47,38%). Dữ liệu **khá cân bằng**, nên tỷ lệ gửi tiền chung 47,38% được dùng làm mốc so sánh.
- **Độ lệch và thiếu dữ liệu cần lưu ý:** `balance` lệch phải rõ rệt (trung bình ≈ 1.529 so với trung vị 550, giá trị lớn nhất 81.204); `poutcome` thiếu tới 74,59% nhưng thực

chất là nhóm chưa từng được liên hệ ở chiến dịch trước (xem mục 2.0), nên được giữ làm một nhãn riêng thay vì điền khuyết.

CHƯƠNG 2. TIỀN XỬ LÝ VÀ LÀM SẠCH DỮ LIỆU

2.1. Kiểm tra sai định dạng và giá trị bất hợp lệ

Phần này minh chứng ba nhóm bất thường: **sai định dạng, trùng lặp, ngoại lệ**. Trùng lặp đã kiểm tra ở mục 1.5, ngoại lệ được xử lý ở mục 2.2; ô dưới kiểm tra phần **sai định dạng**.

Bảng 2.1. Đối chiếu pdays = -1 với poutcome = 'unknown' (số dòng)

	poutcome = 'unknown'	poutcome ≠ 'unknown'
pdays = -1	8.324	0
pdays ≠ -1	2	2.836

Nhận xét 2.0: tháng đều hợp lệ (12 giá trị); tuổi từ 18 đến 95 và ngày từ 1 đến 31 đều nằm trong khoảng hợp lý, không phát hiện lỗi định dạng. `balance` âm là tài khoản thấu chi (dữ liệu thật) nên được giữ nguyên. `pdays = -1` là **mã quy ước** "chưa từng liên hệ" và gần như trùng với `poutcome = unknown` (bảng đối chiếu phía trên), vì vậy được tách thành cột nhị phân `contacted_before` và không đưa vào bước scale ở mục 2.3.

2.2. Dữ liệu trùng lặp

Notebook đã kiểm tra dòng trùng lặp hoàn toàn (mục 1.5): **0 dòng trùng (0,00%)**, nên không cần xóa dòng nào.

2.3. Xử lý giá trị ẩn 'unknown'

Bảng 2.2. Số giá trị 'unknown' trước và sau khi xử lý

Cột	'unknown' trước	'unknown' sau	Tỷ lệ trước (%)	Cách xử lý
job	70	0	0,63	Điền Mode (management)
education	497	0	4,45	Điền Mode (secondary)
contact	2.346	2.346	21,02	Giữ làm nhóm riêng
poutcome	8.326	8.326	74,59	Giữ làm nhóm riêng

Lý do chọn kỹ thuật: `job` và `education` có tỷ lệ `unknown` nhỏ (dưới 5%) nên được điền bằng **Mode** (giá trị xuất hiện nhiều nhất; cột chữ không tính được trung bình hay trung vị). Ngược lại `contact` (21,02%) và `poutcome` (74,59%) có tỷ lệ rất lớn; điền Mode sẽ tạo thông tin giả và làm méo phân phối, trong khi `poutcome = unknown` thực chất là nhóm chưa từng được liên hệ ở chiến dịch trước (trùng với `pdays = -1`). Vì vậy hai cột này được giữ nguyên `unknown` như một nhãn phân loại riêng.

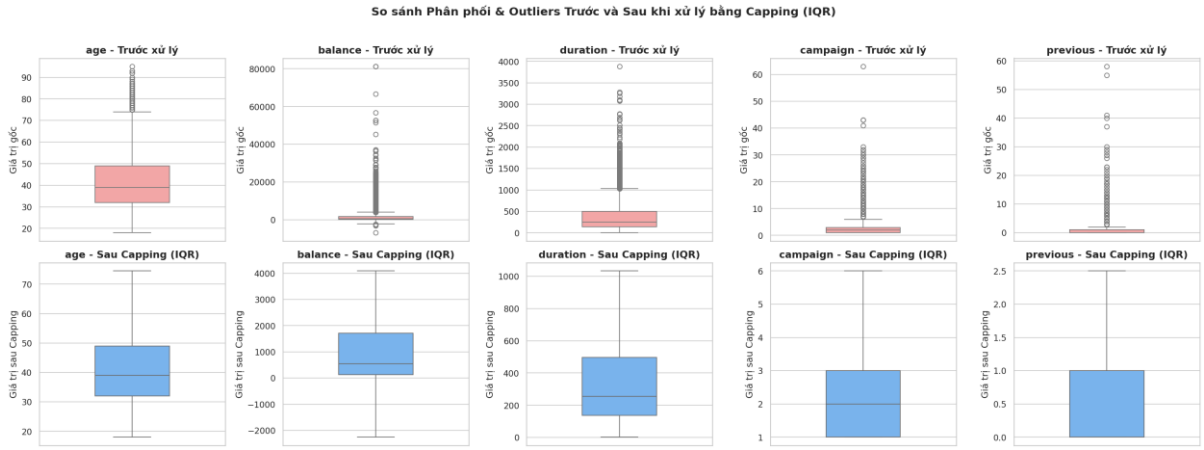
2.4. Phát hiện và xử lý ngoại lệ (outliers) bằng phương pháp IQR

Một giá trị bị coi là ngoại lệ nếu nằm ngoài khoảng từ Q1 − 1,5×IQR đến Q3 + 1,5×IQR, trong đó IQR = Q3 − Q1. Bảng 2.3 thống kê số ngoại lệ của năm biến số.

Bảng 2.3. Thống kê ngoại lệ theo IQR trước khi xử lý

Cột	Q1	Median	Q3	IQR	Ngưỡng dưới	Ngưỡng trên	Số outlier	Tỷ lệ (%)
age	32,0	39,0	49,0	17,0	6,5	74,5	171	1,53
balance	122,0	550,0	1.708,0	1.586,0	-2.257,0	4.087,0	1.055	9,45
duration	138,0	255,0	496,0	358,0	-399,0	1.033,0	636	5,7
campaign	1,0	2,0	3,0	2,0	-2,0	6,0	601	5,38
previous	0,0	0,0	1,0	1,0	-1,5	2,5	1.258	11,27

Nếu xóa mọi dòng có ít nhất một ngoại lệ ở năm cột này, nhóm sẽ mất **3.322 dòng (29,8%)** dữ liệu. Những khách hàng này (số dư rất lớn, cuộc gọi rất dài…) là khách thật chứ không phải lỗi nhập liệu, vì vậy nhóm chọn **capping (winsorization)**: thay giá trị vượt ngưỡng bằng đúng giá trị ngưỡng, giữ nguyên 11.162 dòng. Sau capping, số ngoại lệ ở mọi cột bằng 0 (Hình 2.1).



Hình 2.1. Boxplot trước và sau khi xử lý ngoại lệ bằng capping (IQR)

2.5. Mã hóa (encoding) và chuẩn hóa (scaling): giải trình kỹ thuật

Bảng 2.4. Tổng hợp vấn đề, giải pháp và lý do lựa chọn ở Giai đoạn 2

Vấn đề (số liệu thật)	Giải pháp	Lý do
`unknown` thấp ở `job` (0,63%) và `education` (4,45%)	Điền **Mode** (`management`, `secondary`)	Tỷ lệ nhỏ nên không cần bỏ dòng, ít làm méo phân phối; cột chữ không tính được trung bình
`unknown` cao ở `contact` (21,02%) và `poutcome` (74,59%)	**Giữ làm một nhóm riêng**	Điền bừa tạo thông tin giả; `poutcome = unknown` thực chất là chưa từng liên hệ (trùng với `pdays = -1`)
Outlier ở `balance` (9,45%), `duration` (5,70%), `campaign` (5,38%), `previous`	**Capping IQR**, không xóa	Là khách thật; xóa sẽ mất gần 30% dữ liệu (3.322 dòng, 29,8%, có ít nhất một outlier ở 5 cột); cắt ngưỡng giảm kéo lệch

Vấn đề (số liệu thật)	Giải pháp	Lý do
`pdays = -1` (8.324 dòng)	Tạo `contacted_before`, bỏ `pdays` khỏi scale	-1 là mã, không phải số ngày thật; scale như số sẽ làm sai thang đo
Biến phân loại	Binary (`default, housing, loan, deposit`), Ordinal (`education`, `month`), One-Hot (`job, marital, contact, poutcome`)	One-Hot cho cột không có thứ tự (đánh số sẽ khiến mô hình hiểu nhầm "student > admin"); Ordinal khi có thứ tự tự nhiên; `drop_first=True` tránh đa cộng tuyến
Biến số lệch phải (skewness `balance` ≈ 8,22; `previous` ≈ 7,34; `campaign` ≈ 5,55)	**RobustScaler**	Dựa trên median và IQR nên ít bị outlier kéo lệch; không dùng MinMax vì nhạy với giá trị cực đại

Về `age` và so sánh trước/sau capping: `age` cũng được cắt theo IQR để đồng nhất quy trình (171 dòng, 1,53%, ngưỡng trên 74,5 tuổi); các biểu đồ phân tích ở Phần 3 vẫn dùng dữ liệu gốc nên không mất khách lớn tuổi. Biểu đồ boxplot trước/sau capping cho thấy các điểm ngoại lệ biến mất sau khi cắt, trong khi Q1, trung vị và Q3 giữ nguyên (bảng thống kê sau capping có 0 outlier ở mọi cột). Như vậy capping chỉ cắt phần đuôi chứ không làm thay đổi phần thân của phân phối.

CHƯƠNG 3. PHÂN TÍCH VÀ TRỰC QUAN HÓA

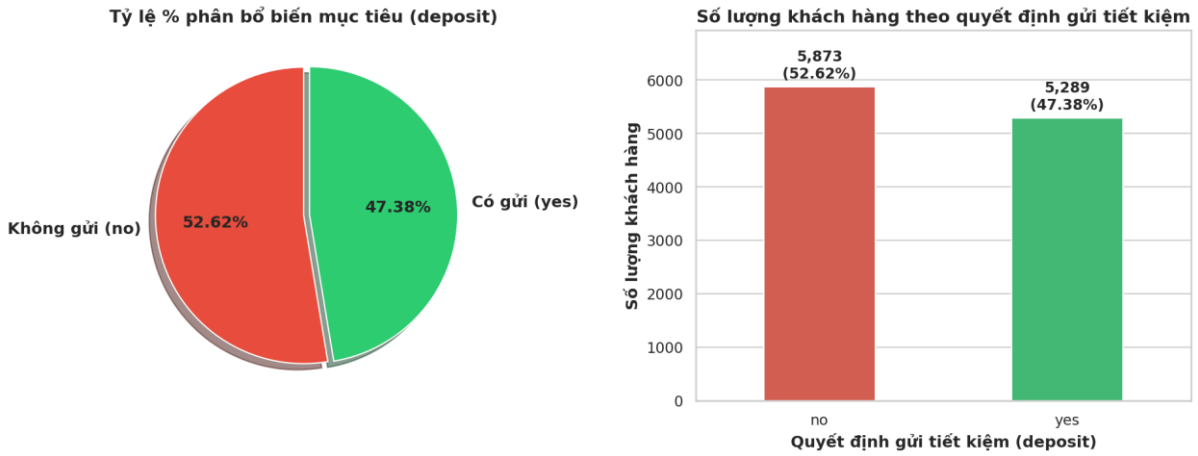
3.1. Giả thuyết cần kiểm định và tổng quan biến mục tiêu

Bảng 3.1. Mười giả thuyết H1-H10 và biểu đồ dùng để kiểm định

Mã	Giả thuyết (đối chiếu số liệu với giả định ban đầu)	Biểu đồ dùng
H1	Khách lớn tuổi có tỷ lệ gửi tiền cao hơn khách trẻ	Biểu đồ 3 (bảng 3B)
H2	Nhóm student, retired cao hơn nhóm blue-collar, services	Biểu đồ 2
H3	Học vấn cao hơn thì tỷ lệ cao hơn; khách độc thân cao hơn khách đã kết hôn	Biểu đồ 2 và 8
H4	Số dư cao hơn thì tỷ lệ gửi tiền cao hơn	Biểu đồ 3 và 3C
H5	Khách có vay nhà, vay cá nhân hoặc nợ xấu có tỷ lệ thấp hơn	Biểu đồ 7
H6	Tỷ lệ khác nhau rõ giữa các tháng; tháng ít cuộc gọi thì kém tin cậy	Biểu đồ 5
H7	Gọi qua cellular hiệu quả hơn telephone và unknown	Biểu đồ 9
H8	Cuộc gọi dài hơn thì tỷ lệ cao hơn (là **kết quả**, không phải nguyên nhân)	Biểu đồ 4
H9	Gọi càng nhiều lần thì tỷ lệ càng giảm (tìm ngưỡng dừng)	Biểu đồ 4 và 4D
H10	Khách có `poutcome = success` có tỷ lệ cao hơn rất nhiều	Biểu đồ 5

Dưới mỗi biểu đồ là phần **Deep Insight** gồm bốn ý: số liệu cụ thể, so sánh, kết luận giả thuyết và bài học hành động. Các nhóm có quá ít khách được chỉ rõ vì kết luận kém tin cậy.

Ghi chú: số thứ tự "Biểu đồ" trong bảng trên và trong các đoạn phân tích tương ứng với nhãn "Biểu đồ N trong notebook" ghi dưới mỗi hình của báo cáo (ví dụ Hình 3.4 là Biểu đồ 3C).



Hình 3.1. Tỷ lệ phân bổ biến mục tiêu deposit (yes/no) *(Biểu đồ 1 trong notebook)*

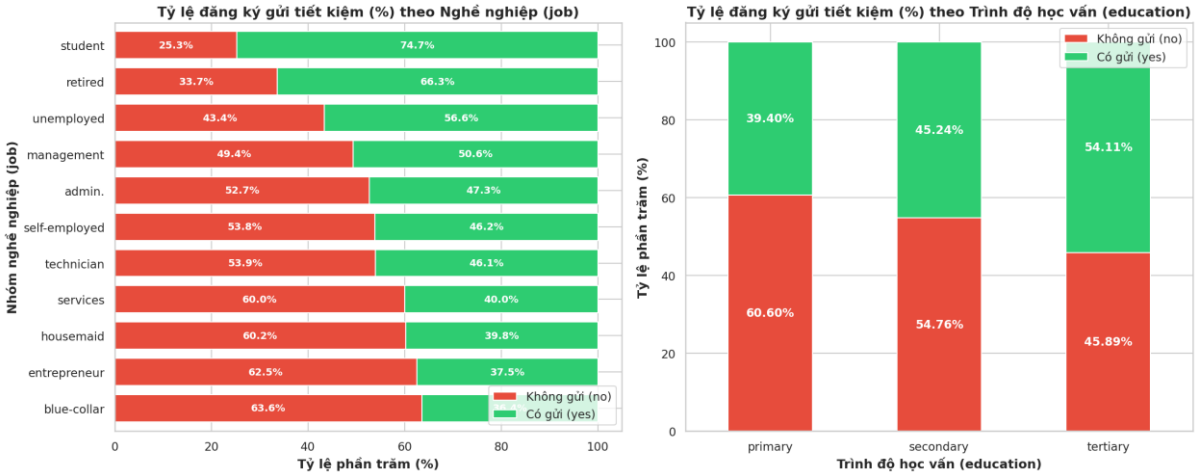
Deep Insight - mục 3.1: phân bố deposit

Giả thuyết: dữ liệu có cân bằng giữa hai lớp yes/no hay không.

- **Số liệu cụ thể:** 5.289 khách đăng ký (yes, 47,38%) và 5.873 khách từ chối (no, 52,62%) trên tổng 11.162 khách.
- **So sánh:** hai lớp chỉ chênh nhau khoảng 5,2 điểm phần trăm, chưa đến mức mất cân bằng.

- **Kết luận giả thuyết:** dữ liệu **khá cân bằng**, không cần kỹ thuật cân bằng lớp; tỷ lệ 47,38% được dùng làm mốc so sánh cho mọi biểu đồ phía sau.
- **Bài học / hành động:** gần một nửa khách được gọi đã đăng ký, nên việc cần tối ưu là chọn đúng nhóm khách và cách tiếp cận để nâng tỷ lệ này, thay vì tăng số cuộc gọi một cách đại trà.

3.2. Phân tích nhóm khách hàng (H1-H5)

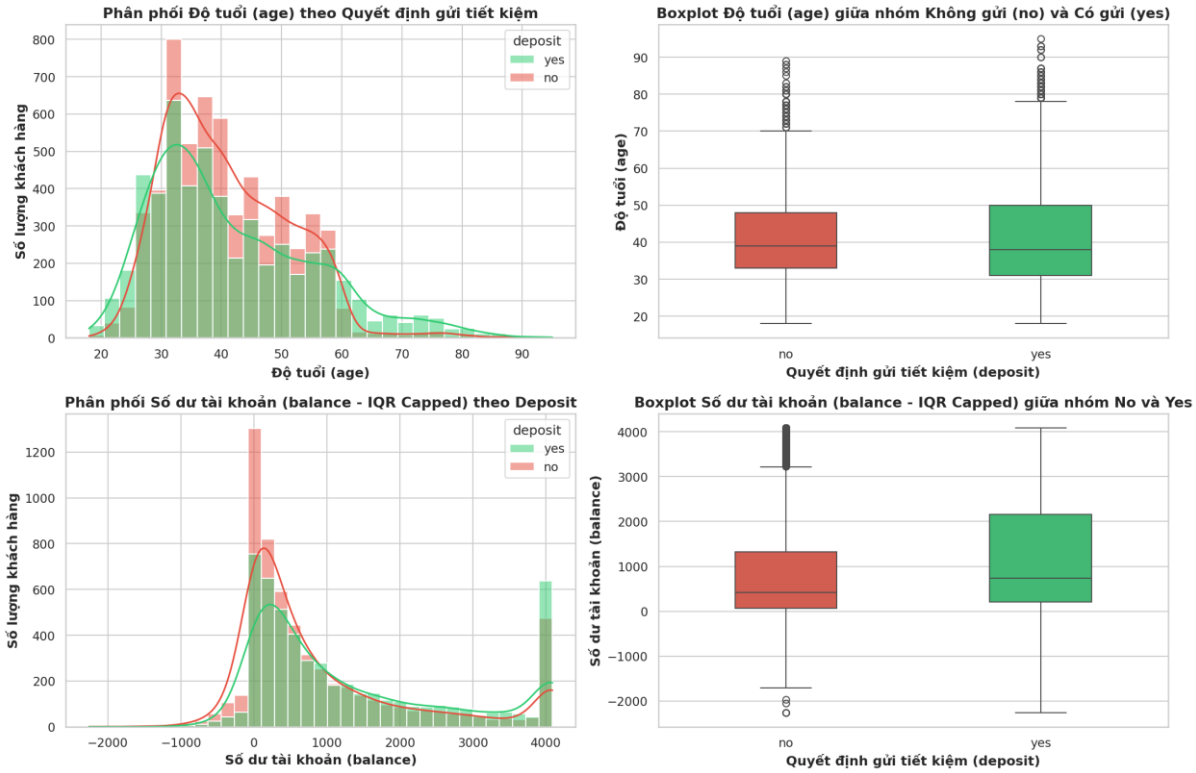


Hình 3.2. Tỷ lệ gửi tiền theo nghề nghiệp và trình độ học vấn *(Biểu đồ 2 trong notebook)*

Deep Insight - H2, H3a: nghề nghiệp và học vấn

Giả thuyết: student, retired cao hơn blue-collar, services; học vấn cao hơn thì tỷ lệ cao hơn.

- **Số liệu cụ thể:** hai nghề cao nhất là student 74,72% (n = 360) và retired 66,32% (n = 778); hai nghề thấp nhất là blue-collar 36,42% (n = 1.944) và entrepreneur 37,50% (n = 328). Theo học vấn: primary 39,40% (n = 1.500), secondary 45,24% (n = 5.973), tertiary 54,11% (n = 3.689).
- **So sánh:** student cao hơn mức chung 47,38% đến 27,34 điểm % và cao hơn blue-collar 38,30 điểm %; retired cao hơn mức chung 18,94 điểm %. Nhóm tertiary cao hơn primary 14,71 điểm %. Các nhóm chính đều có n từ vài trăm trở lên nên đủ tin cậy.
- **Kết luận giả thuyết: H2 được ủng hộ** (student, retired vượt xa blue-collar, services); **H3a được ủng hộ** vì tỷ lệ tăng đều theo trình độ học vấn.
- **Bài học / hành động:** ưu tiên gọi student, retired và cả unemployed (56,58%, n = 357); giảm dồn cuộc gọi vào blue-collar (1.944 khách nhưng chỉ 36,42% đăng ký) và nhóm trình độ primary.

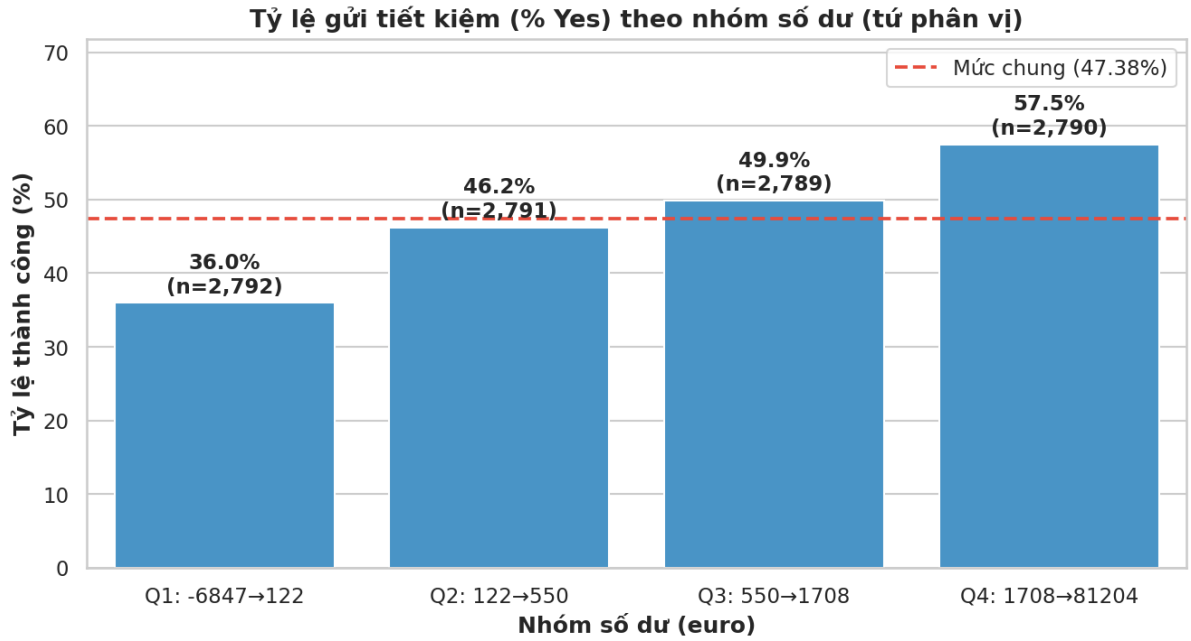


Hình 3.3. Phân phối tuổi và số dư tài khoản theo quyết định gửi tiền *(Biểu đồ 3 trong notebook)*

Deep Insight - H1, H4: tuổi và số dư

Giả thuyết: khách lớn tuổi gửi nhiều hơn; số dư cao hơn thì gửi nhiều hơn.

- **Số liệu cụ thể:** theo nhóm tuổi: ≤ 25 là 71,11% (n = 450); 26-35 là 47,67% (n = 3.921); 36-50 là 41,37% (n = 4.320); 51-60 là 43,60% (n = 1.860); > 60 là 82,16% (n = 611). Tuổi trung bình nhóm yes 41,67 và nhóm no 40,84. Về số dư, trung vị nhóm yes là 733 so với 414 của nhóm no (trung bình 1.804 so với 1.280).
- **So sánh:** nhóm > 60 cao hơn mức chung 34,78 điểm %, nhóm ≤ 25 cao hơn 23,73 điểm %, trong khi nhóm 36-50 thấp hơn 6,01 điểm %. Tuổi trung bình hai nhóm chỉ chênh 0,83 năm, nên tuổi trung bình không phản ánh được sự khác biệt này. Trung vị số dư nhóm yes gấp khoảng 1,8 lần nhóm no; vì số dư lệch phải nên dùng trung vị thay cho trung bình.
- **Kết luận giả thuyết: H1 được ủng hộ một phần:** tỷ lệ có dạng **chữ U** (cao ở nhóm trẻ ≤ 25 và nhóm > 60), không phải "tuổi càng cao càng gửi". **H4 được ủng hộ** theo trung vị số dư.
- **Bài học / hành động:** ưu tiên nhóm > 60 và nhóm ≤ 25; nhóm 36-50 đông nhất (4.320 khách) nhưng tỷ lệ thấp nhất nên cần kịch bản tư vấn riêng thay vì gọi đại trà.

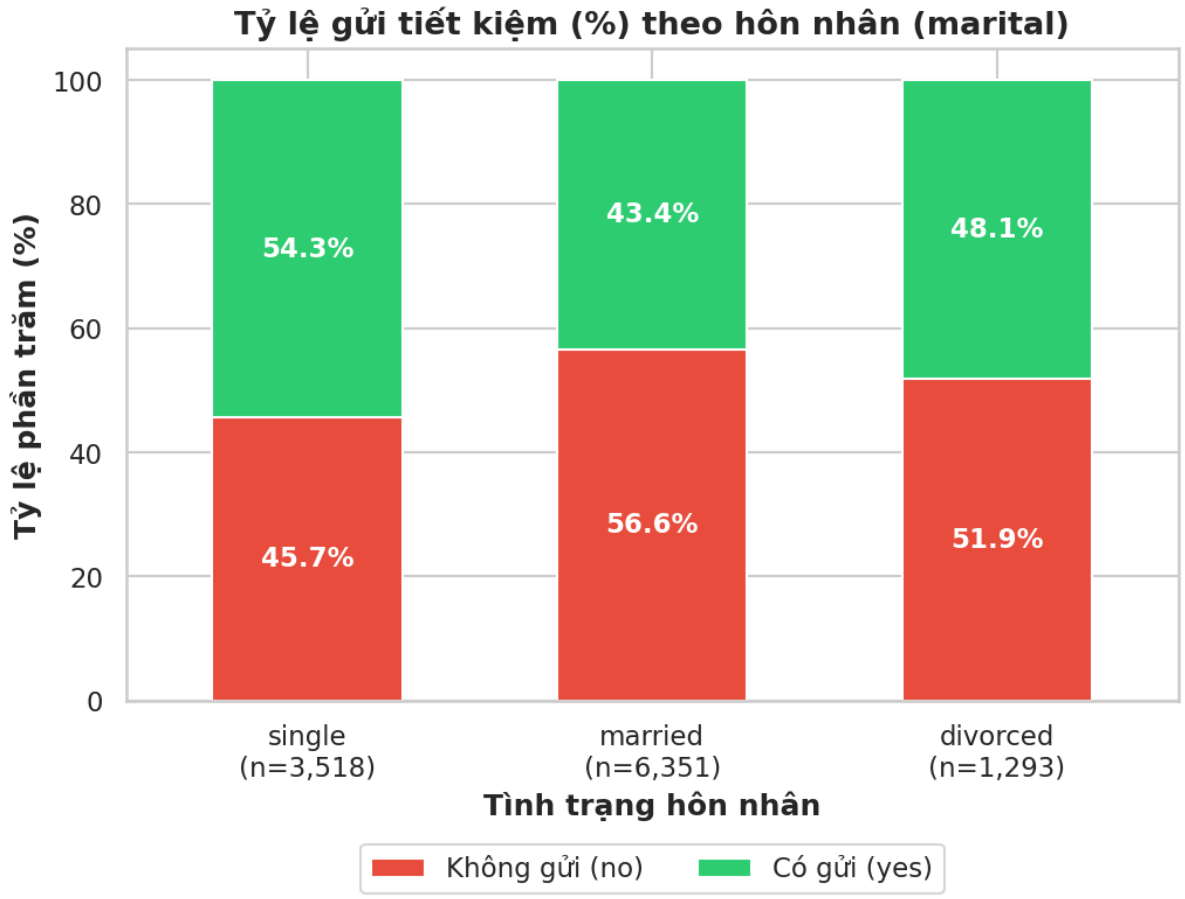


Hình 3.4. Tỷ lệ gửi tiền theo 4 nhóm số dư (tứ phân vị) *(Biểu đồ 3C trong notebook)*

Deep Insight - H4: nhóm số dư

Giả thuyết: số dư cao hơn thì tỷ lệ gửi tiền cao hơn.

- **Số liệu cụ thể:** theo tứ phân vị số dư: Q1 (từ -6.847 đến 122) là 35,96% (n = 2.792); Q2 (122 đến 550) là 46,22% (n = 2.791); Q3 (550 đến 1.708) là 49,87% (n = 2.789); Q4 (1.708 đến 81.204) là 57,49% (n = 2.790).
- **So sánh:** tỷ lệ tăng đều qua từng nhóm; Q4 cao hơn Q1 là 21,53 điểm %, Q1 thấp hơn mức chung 11,42 điểm % và Q4 cao hơn mức chung 10,11 điểm %. Bốn nhóm có cỡ mẫu gần bằng nhau (khoảng 2.790 khách) nên so sánh đáng tin cậy.
- **Kết luận giả thuyết: H4 được ủng hộ rõ rệt:** số dư càng cao thì khả năng gửi tiền càng cao.
- **Bài học / hành động:** ưu tiên khách có số dư trên 1.708 euro (nhóm Q4); với khách số dư thấp (từ 122 euro trở xuống) tỷ lệ chỉ 35,96%, nên cân nhắc giảm cường độ gọi hoặc đổi sản phẩm phù hợp hơn.

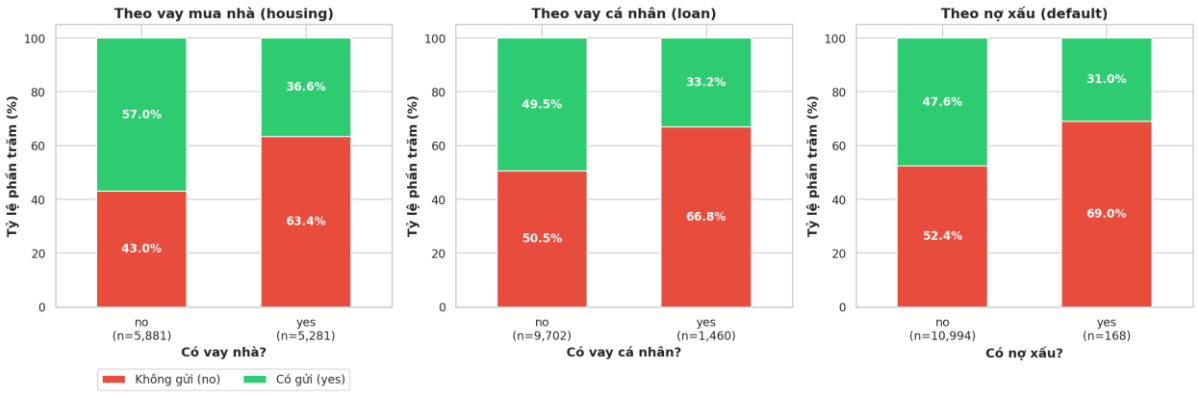


Hình 3.5. Tỷ lệ gửi tiền theo tình trạng hôn nhân *(Biểu đồ 8 trong notebook)*

Deep Insight - H3b: hôn nhân

Giả thuyết: khách độc thân gửi nhiều hơn khách đã kết hôn.

- **Số liệu cụ thể:** single 54,35% (n = 3.518); married 43,38% (n = 6.351); divorced 48,11% (n = 1.293).
- **So sánh:** khách độc thân cao hơn khách đã kết hôn 10,97 điểm %, cao hơn mức chung 6,97 điểm %; nhóm married thấp hơn mức chung 4,00 điểm %. Cả ba nhóm đều có n từ 1.293 trở lên nên đủ tin cậy.
- **Kết luận giả thuyết: H3b được ủng hộ:** độc thân gửi nhiều hơn rõ rệt; chênh lệch gần 11 điểm % là đáng kể (xem thêm kiểm định Chi-square ở mục 3.4).
- **Bài học / hành động:** ưu tiên khách độc thân; với khách đã kết hôn (nhóm đông nhất, 6.351 khách) nên thử cách tiếp cận theo nhu cầu gia đình.



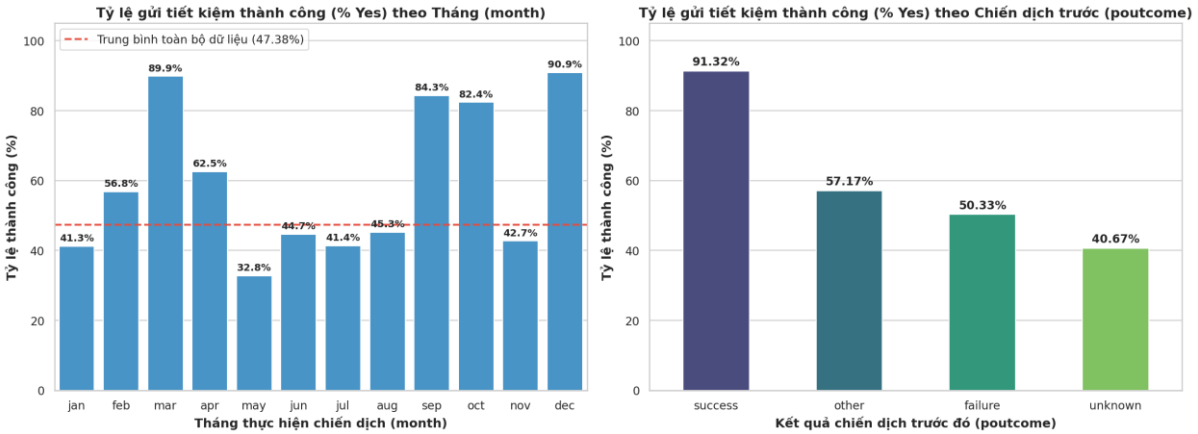
Hình 3.6. Tỷ lệ gửi tiền theo vay nhà, vay cá nhân và nợ xấu *(Biểu đồ 7 trong notebook)*

Deep Insight - H5: vay nhà, vay cá nhân, nợ xấu

Giả thuyết: khách có vay hoặc nợ xấu có tỷ lệ gửi tiền thấp hơn.

- **Số liệu cụ thể:** vay nhà: no 57,03% (n = 5.881) và yes 36,64% (n = 5.281); vay cá nhân: no 49,53% (n = 9.702) và yes 33,15% (n = 1.460); nợ xấu: no 47,64% (n = 10.994) và yes 30,95% (n = 168).
- **So sánh:** chênh lệch giữa nhóm không vay và có vay là 20,39 điểm % với vay nhà, 16,38 điểm % với vay cá nhân và 16,69 điểm % với nợ xấu. Nhóm `default = yes` chỉ có 168 khách (khoảng 1,5% dữ liệu) nên kết luận kém tin cậy hơn hai biến còn lại.
- **Kết luận giả thuyết: H5 được ủng hộ** ở cả ba biến, mạnh nhất là vay nhà.
- **Bài học / hành động:** ưu tiên khách không có vay nhà và không vay cá nhân; khách đang gánh nợ ít có dư địa tiết kiệm nên cần sản phẩm hoặc cách tư vấn phù hợp hơn.

3.3. Phân tích chiến dịch tiếp thị (H6-H10)

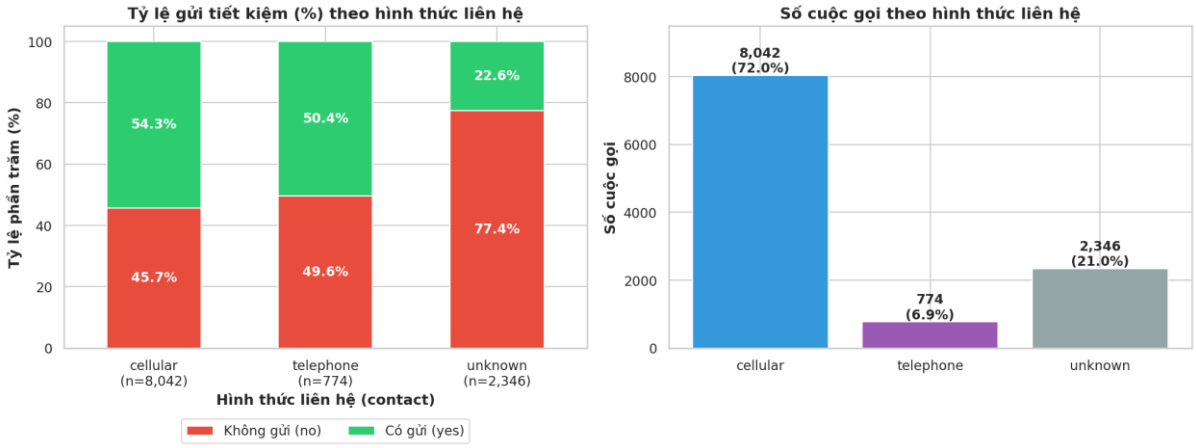


Hình 3.7. Tỷ lệ gửi tiền theo tháng và theo kết quả chiến dịch trước *(Biểu đồ 5 trong notebook)*

Deep Insight - H6, H10: tháng và kết quả chiến dịch trước

Giả thuyết: tỷ lệ khác nhau rõ giữa các tháng (tháng ít cuộc gọi kém tin cậy); `poutcome = success` cao hơn rất nhiều.

- **Số liệu cụ thể:** tháng 5 có 2.824 cuộc gọi (25,30% toàn chiến dịch) nhưng chỉ 32,75% đăng ký. Các tháng mar (89,86%, n = 276), sep (84,33%, n = 319), oct (82,40%, n = 392) và dec (90,91%, n = 110) đạt tỷ lệ rất cao; apr 62,51% (n = 923) và feb 56,83% (n = 776) cũng vượt mức chung. Theo kết quả chiến dịch trước: success 91,32% (n = 1.071); other 57,17% (n = 537); failure 50,33% (n = 1.228); unknown 40,67% (n = 8.326).
- **So sánh:** tháng 5 thấp hơn mức chung 14,63 điểm %. Nhóm success cao hơn mức chung 43,94 điểm % và cao hơn nhóm unknown 50,65 điểm %; ngay cả nhóm failure vẫn cao hơn mức chung 2,95 điểm %. Bốn tháng mar, sep, oct, dec chỉ có từ 110 đến 392 cuộc gọi nên kém tin cậy hơn apr và feb.
- **Kết luận giả thuyết: H6 được ủng hộ** (tỷ lệ khác biệt rõ giữa các tháng, kèm lưu ý về tháng ít dữ liệu); **H10 được ủng hộ rất mạnh.**
- **Bài học / hành động:** không dồn quá nhiều cuộc gọi vào tháng 5; ưu tiên gọi lại khách từng success ở chiến dịch trước, đồng thời cân nhắc tăng nguồn lực cho các tháng apr, feb và những tháng cuối năm sau khi kiểm chứng thêm bằng dữ liệu nhiều năm.



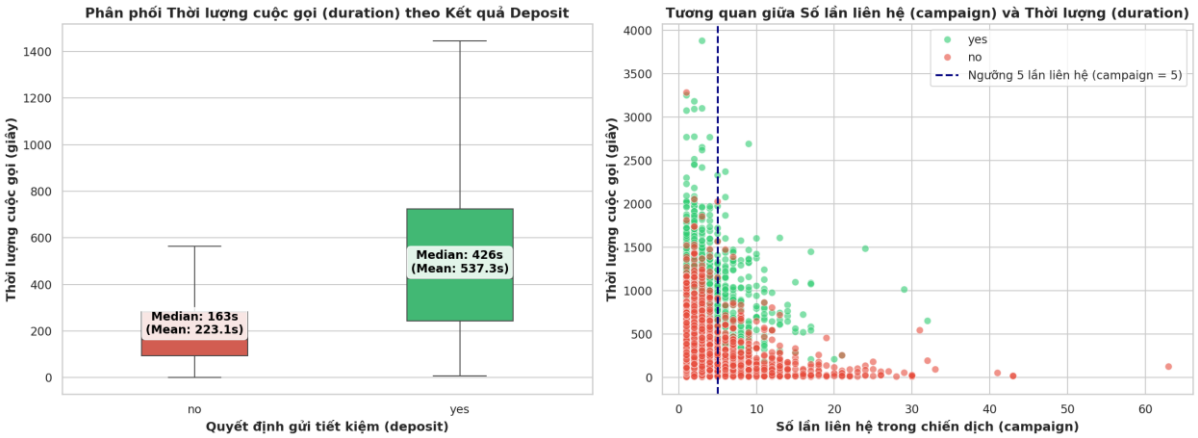
Hình 3.8. Tỷ lệ gửi tiền và số cuộc gọi theo hình thức liên hệ *(Biểu đồ 9 trong notebook)*

Deep Insight - H7: hình thức liên hệ

Giả thuyết: gọi qua cellular hiệu quả hơn telephone và unknown.

- **Số liệu cụ thể:** cellular 54,33% (n = 8.042); telephone 50,39% (n = 774); unknown 22,59% (n = 2.346).

- **So sánh:** cellular cao hơn telephone chỉ 3,94 điểm % (nhóm telephone chỉ có 774 khách), nhưng cao hơn unknown tới 31,74 điểm %. Nhóm `unknown` chiếm 21,02% dữ liệu và thấp hơn mức chung 24,79 điểm %.
- **Kết luận giả thuyết: H7 được ủng hộ một phần:** cellular cao nhất, nhưng chênh lệch với telephone nhỏ; điểm khác biệt lớn nhất là nhóm `unknown` thấp rõ rệt, có thể liên quan đến việc không xác định được kênh liên hệ (đây là giả thuyết, chưa kiểm chứng được bằng dữ liệu).
- **Bài học / hành động:** ưu tiên liên lạc qua điện thoại di động và ghi nhận đầy đủ kênh liên hệ của từng cuộc gọi để phân tích chính xác hơn.



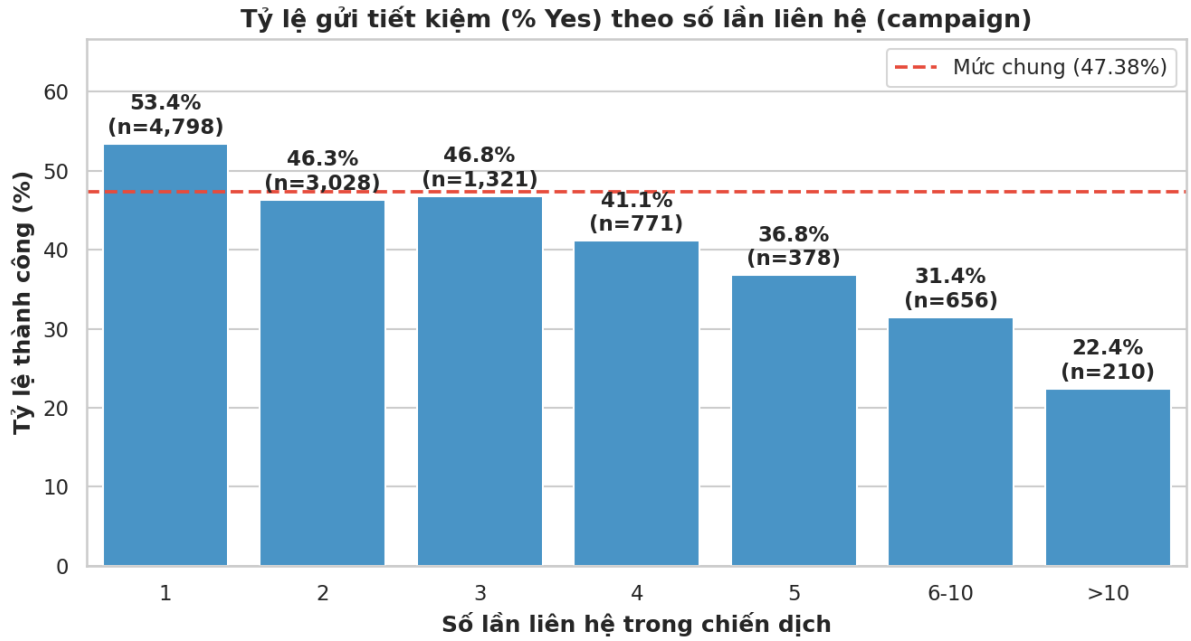
Hình 3.9. Thời lượng cuộc gọi và số lần liên hệ theo kết quả deposit *(Biểu đồ 4 trong notebook)*

Deep Insight - H8, H9: thời lượng và số lần gọi

Giả thuyết: cuộc gọi dài hơn thì tỷ lệ cao hơn; gọi nhiều lần thì tỷ lệ giảm.

- **Số liệu cụ thể:** theo thời lượng: ≤ 3 phút là 18,01% (n = 3.936); 3-5 phút là 46,10% (n = 2.434); 5-10 phút là 61,55% (n = 2.640); > 10 phút là 85,18% (n = 2.152). Trung vị thời lượng nhóm yes là 426 giây so với 163 giây của nhóm no. Theo số lần gọi: 1 lần 53,38%; 2-3 lần 46,42%; 4-5 lần 39,69%; > 5 lần 29,21%.
- **So sánh:** tỷ lệ nhóm > 10 phút cao hơn nhóm ≤ 3 phút tới 67,17 điểm %, và trung vị thời lượng nhóm yes gấp khoảng 2,6 lần nhóm no. Về số lần gọi, tỷ lệ giảm 24,17 điểm % từ 1 lần xuống trên 5 lần. Đường đứng `campaign = 5` trên biểu đồ phân tán là mốc tham chiếu; ở biểu đồ 4D, tại 5 lần gọi tỷ lệ là 36,77%, thấp hơn mức chung 10,61 điểm %.
- **Kết luận giả thuyết: H8 được ủng hộ mạnh** nhưng `duration` chỉ biết **sau** cuộc gọi nên là kết quả chứ không phải nguyên nhân; **H9 được ủng hộ** vì tỷ lệ giảm dần khi gọi nhiều lần.

- **Bài học / hành động:** không dùng `duration` để chọn khách trước khi gọi; chỉ dùng như tín hiệu theo dõi (cuộc gọi kéo dài trên 5 phút thường là khách quan tâm). Nên giới hạn số lần gọi mỗi khách để tránh tốn chi phí và làm phiền khách.



Hình 3.10. Tỷ lệ gửi tiền theo từng mức số lần gọi và ngưỡng dừng đề xuất *(Biểu đồ 4D trong notebook)*

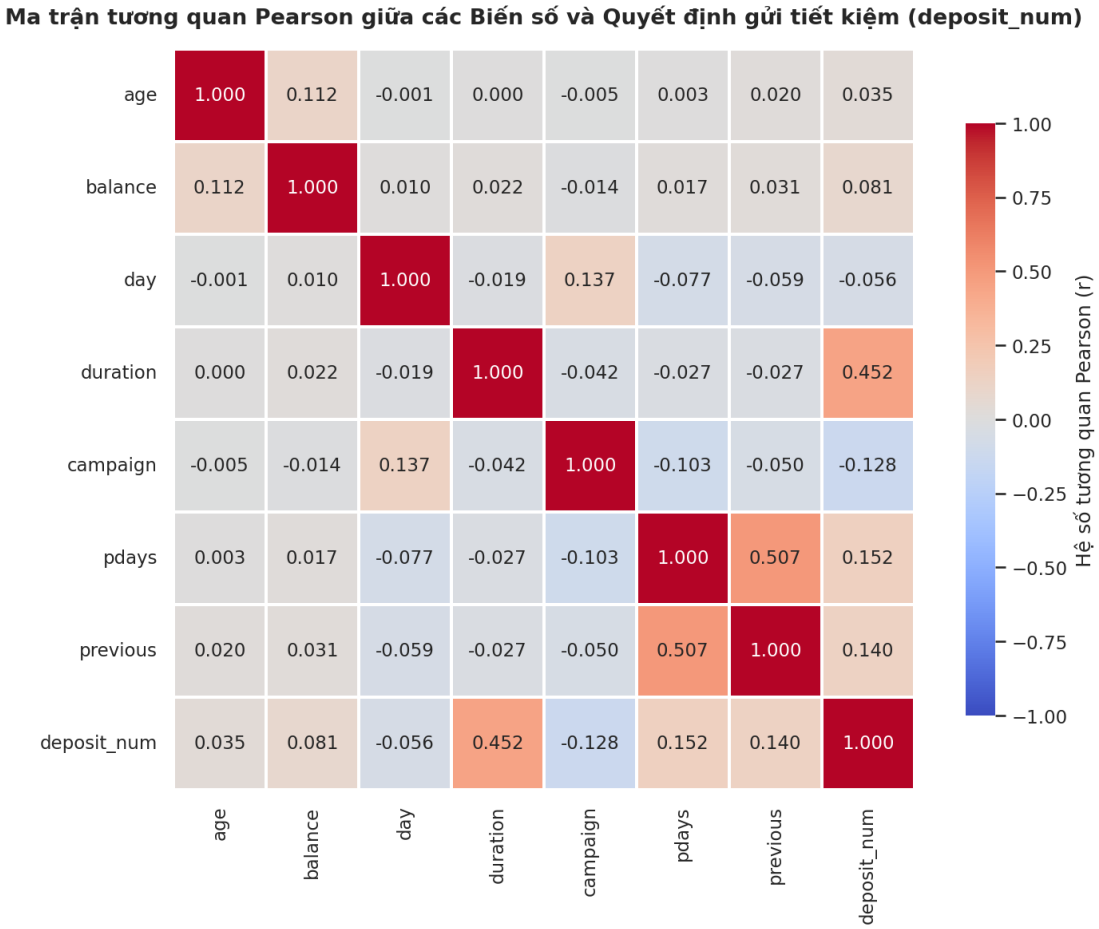
Deep Insight - H9: ngưỡng dừng số lần gọi

Giả thuyết: gọi càng nhiều lần thì tỷ lệ càng giảm.

- **Số liệu cụ thể:** theo từng mức số lần gọi: 1 lần 53,38% (n = 4.798); 2 lần 46,27% (n = 3.028); 3 lần 46,78% (n = 1.321); 4 lần 41,12% (n = 771); 5 lần 36,77% (n = 378); 6-10 lần 31,40% (n = 656); trên 10 lần 22,38% (n = 210).
- **So sánh:** tỷ lệ giảm gần đơn điệu (riêng 2 và 3 lần gần như ngang nhau, chênh 0,51 điểm %). Nhóm trên 10 lần thấp hơn mức chung tới 25,00 điểm %, nhưng chỉ có 210 khách nên cần thận trọng khi khái quát.
- **Kết luận giả thuyết: H9 được ủng hộ.** Với tiêu chí "thấp hơn mức chung ít nhất 5 điểm %", nhóm đầu tiên vượt tiêu chí là **4 lần gọi** (41,12%, thấp hơn mức chung 6,26 điểm %).
- **Bài học / hành động:** đặt ngưỡng dừng **tối đa 3 lần gọi mỗi khách**; từ lần thứ 4 trở đi hiệu quả mỗi cuộc gọi thấp hơn mức chung rõ rệt.

Đề xuất cho Giai đoạn 4: ngưỡng dừng tối đa 3 lần gọi mỗi khách (tiêu chí: thấp hơn mức chung ít nhất 5 điểm %).

3.4. Tương quan và kiểm định thống kê



Hình 3.11. Ma trận tương quan Pearson giữa các biến số và deposit *(Biểu đồ 6 trong notebook)*

Deep Insight - mục 3.4: tương quan Pearson

Giả thuyết: biến số nào tương quan mạnh nhất với `deposit_num`.

- **Số liệu cụ thể:** hệ số tương quan với deposit (giảm dần): duration 0,45; pdays 0,15; previous 0,14; balance 0,08; age 0,03; day -0,06; campaign -0,13. Giữa pdays và previous là 0,51.
- **So sánh:** `duration` tương quan mạnh hơn hẳn các biến còn lại (gấp khoảng 3 lần pdays). Các biến còn lại chỉ ở mức yếu (từ -0,13 đến 0,15). Cặp pdays và previous tương quan khá mạnh với nhau (0,51), nên mang thông tin chồng lấn.
- **Kết luận giả thuyết:** `duration` là biến liên quan nhất đến kết quả nhưng chỉ biết sau cuộc gọi nên không phải nguyên nhân; hệ số Pearson chỉ đo quan hệ **tuyến tính** và **tương quan không đồng nghĩa nhân quả**. Với `pdays` cần thận trọng khi diễn giải vì biến này chứa mã -1.
- **Bài học / hành động:** các yếu tố hành động được trước cuộc gọi (số lần gọi, nhóm khách, tháng) có tương quan tuyến tính yếu nhưng vẫn có tác động rõ khi chia theo

nhóm (xem các biểu đồ trên), nên cần đọc cùng bảng tỷ lệ theo nhóm chứ không chỉ dựa vào hệ số tương quan.

- **Chi-square:** kiểm tra biến phân loại có liên hệ thật với `deposit` không (H0: hai biến độc lập). **Cramér's V** đo *độ mạnh* của liên hệ (0 đến 1).
- **t-test (Welch) và Mann-Whitney:** kiểm tra biến số giữa nhóm yes và no có khác biệt thật không. Mann-Whitney làm đối chứng vì các biến lệch phải.
- **Cách đọc p-value:** p-value < 0,05 nghĩa là khác biệt khó có thể chỉ do ngẫu nhiên. Dữ liệu hơn 11 nghìn dòng nên p-value thường rất nhỏ; cần xem thêm **mức chênh thực tế** và Cramér's V.

Bảng 3.2. Kết quả kiểm định Chi-square và Cramér's V giữa biến phân loại và deposit

Biến	Chi2	Bậc tự do	p-value	Cramér's V	Mức độ liên hệ	Kết luận (α = 0,05)
job	378,0	10	4,61e-75	0,184	yếu	Có liên hệ với deposit
marital	109,6	2	1,60e-24	0,099	rất yếu	Có liên hệ với deposit
education	116,3	2	5,65e-26	0,102	yếu	Có liên hệ với deposit
default	17,8	1	2,44e-05	0,041	rất yếu	Có liên hệ với deposit
housing	463,2	1	9,72e-103	0,204	yếu	Có liên hệ với deposit
loan	135,8	1	2,17e-31	0,111	yếu	Có liên hệ với deposit
contact	736,7	2	1,07e-160	0,257	yếu	Có liên hệ với deposit
month	1.046,8	11	1,64e-217	0,306	vừa	Có liên hệ với deposit
poutcome	1.004,6	3	1,78e-217	0,300	vừa	Có liên hệ với deposit
age_group	471,6	4	9,49e-101	0,206	yếu	Có liên hệ với deposit

Bảng 3.3. Kết quả t-test (Welch) và Mann-Whitney giữa nhóm yes và nhóm no

Biến	Trung vị yes	Trung vị no	TB yes	TB no	p t-test	p Mann-Whitney	Kết luận
age	38	39	41,7	40,8	2,76e-04	1,99e-01	Hai phép không thống nhất, cần thận trọng
balance	733	414	1.804,3	1.280,2	1,81e-17	3,13e-62	Khác biệt có ý nghĩa
duration	426	163	537,3	223,1	0,00e+00	0,00e+00	Khác biệt có ý nghĩa
campaign	2	2	2,1	2,8	4,77e-44	7,73e-41	Khác biệt có ý nghĩa
previous	0	0	1,2	0,5	1,36e-48	2,60e-130	Khác biệt có ý nghĩa
day	15	16	15,2	16,1	2,71e-09	7,19e-10	Khác biệt có ý nghĩa

Deep Insight - Kiểm định Chi-square, t-test, Mann-Whitney

Giả thuyết: các biến có liên hệ thật với `deposit` hay chỉ do ngẫu nhiên.

- **Số liệu cụ thể:** Chi-square cho thấy cả 10 biến phân loại đều có liên hệ có ý nghĩa với `deposit` (p < 0,05); mạnh nhất theo Cramér's V là `month` (V = 0,306), `poutcome` (V = 0,300) và `contact` (V = 0,257). Với biến số, t-test và Mann-Whitney đều cho

khác biệt có ý nghĩa ở balance, duration, campaign, previous, day; riêng age hai phép không thống nhất (tuổi trung bình yes 41,67 so với no 40,84).

- **So sánh:** dữ liệu hơn 11 nghìn dòng nên p-value thường rất nhỏ (giá trị hiển thị `0.00e+00` nghĩa là $p < 0{,}001$); vì vậy cần xem thêm mức chênh thực tế và Cramér's V. Các giá trị V quanh 0,26 đến 0,31 cho thấy liên hệ ở mức vừa phải chứ không quá mạnh.
- **Kết luận giả thuyết:** các kết quả kiểm định **xác nhận** hướng của H1 đến H10 ở mức có ý nghĩa thống kê; riêng tuổi cần thận trọng vì tuổi trung bình hai nhóm gần như bằng nhau, sự khác biệt chủ yếu nằm ở dạng chữ U theo nhóm tuổi.
- **Bài học / hành động:** khi lập kế hoạch tiếp thị nên ưu tiên các yếu tố có liên hệ mạnh nhất là tháng, kết quả chiến dịch trước và hình thức liên hệ, và đọc kèm bảng tỷ lệ theo nhóm thay vì chỉ dựa vào p-value.

3.5. Bảng tổng hợp giả thuyết H1-H10

Bảng 3.4. Tổng hợp kết quả kiểm định các giả thuyết H1-H10 (số liệu tự tính từ dữ liệu)

Giả thuyết	Nội dung	Số liệu chính	Kết luận
H1	Khách lớn tuổi gửi nhiều hơn khách trẻ	>60 82,2% (n=611) so với 36-50 41,4% (n=4.320); chung 47,4%	Ủng hộ một phần (dạng chữ U: nhóm ≤25 và >60 cao)
H2	Student, retired cao hơn blue-collar, services	student 74,7% (n=360) so với blue-collar 36,4% (n=1.944); chung 47,4%	Ủng hộ
H3	Học vấn cao và độc thân gửi nhiều hơn	Học vấn: tertiary 54,1% (n=3.689) so với primary 39,4% (n=1.500); chung 47,4% | Hôn nhân: single 54,4% (n=3.518) so với married 43,4% (n=6.351); chung 47,4%	Ủng hộ
H4	Số dư cao thì tỷ lệ cao hơn	Q4 57,5% (n=2.790) so với Q1 36,0% (n=2.792); chung 47,4%	Ủng hộ
H5	Có vay hoặc nợ xấu thì tỷ lệ thấp hơn	Vay nhà: no 57,0% (n=5.881) so với yes 36,6% (n=5.281); chung 47,4% | Vay cá nhân: no 49,5% (n=9.702) so với yes 33,1% (n=1.460); chung 47,4% | Nợ xấu: no 47,6% (n=10.994) so với yes 30,9% (n=168); chung 47,4%	Ủng hộ (nhóm nợ xấu chỉ có 168 khách)
H6	Tỷ lệ khác nhau rõ giữa các tháng	dec 90,9% (n=110) so với may 32,8% (n=2.824); chung 47,4%	Ủng hộ (tháng ít cuộc gọi kém tin cậy)
H7	Cellular hiệu quả hơn telephone và unknown	cellular 54,3% (n=8.042) so với unknown 22,6% (n=2.346); chung 47,4%	Ủng hộ một phần (cellular cao nhất nhưng chênh telephone nhỏ)
H8	Gọi lâu hơn thì tỷ lệ cao hơn (là kết quả)	>10p 85,2% (n=2.152) so với ≤3p 18,0% (n=3.936); chung 47,4%	Ủng hộ (là kết quả sau cuộc gọi)
H9	Gọi nhiều lần thì tỷ lệ giảm	1 53,4% (n=4.798) so với >10 22,4% (n=210); chung 47,4%	Ủng hộ
H10	poutcome = success cao hơn rất nhiều	success 91,3% (n=1.071) so với unknown 40,7% (n=8.326); chung 47,4%	Ủng hộ rất mạnh

CHƯƠNG 4. ĐÁNH GIÁ TÁC ĐỘNG VÀ KHUYẾN NGHỊ

4.1. Các phát hiện nổi bật nhất

1. **Kết quả chiến dịch trước phân biệt khách rất rõ:** khách `poutcome = success` gửi tiền 91,32% (n = 1.071), cao hơn mức chung 47,38% khoảng 43,9 điểm %; nhóm `unknown` chỉ 40,67% (n = 8.326).
2. **Hiệu quả không đi cùng khối lượng cuộc gọi theo tháng:** tháng 5 chiếm 25,30% số cuộc gọi (2.824) nhưng chỉ 32,75% đăng ký, thấp hơn mức chung; các tháng 3, 9, 10, 12 đạt 82-91% nhưng ít cuộc gọi (110-392) nên cần thận trọng khi khái quát.
3. **Gọi nhiều lần làm giảm hiệu quả:** tỷ lệ giảm từ 53,38% (1 lần) xuống 22,38% (> 10 lần); từ nhóm **4 lần gọi** tỷ lệ thấp hơn mức chung ít nhất 5 điểm %.
4. **Nhóm khách có xác suất cao:** khách > 60 tuổi 82,16% (n = 611), student 74,72% (n = 360), retired 66,32%; nhóm có vay nhà thấp hơn rõ (36,6% so với 57,0% ở nhóm không vay).
5. **Thời lượng cuộc gọi liên quan rất mạnh đến kết quả** (> 10 phút đạt 85,18%, ≤ 3 phút chỉ 18,01%) nhưng đây là **kết quả sau cuộc gọi**, không dùng để hành động trước cuộc gọi.

4.2. Giải pháp thực tế (Hành động → Căn cứ số liệu → Lợi ích kỳ vọng)

Bảng 4.1. Đề xuất hành động dựa trên số liệu

Hành động	Căn cứ số liệu	Lợi ích kỳ vọng
Ưu tiên gọi lại khách đã từng `success` ở chiến dịch trước	H10: 91,3% so với mức chung 47,4%	Tăng tỷ lệ chuyển đổi, giảm chi phí mỗi khách thành công
Đặt ngưỡng dừng tối đa 3 lần gọi mỗi khách (từ lần thứ 4 tỷ lệ thấp hơn mức chung ít nhất 5 điểm %, theo biểu đồ 4D)	H9: tỷ lệ giảm từ 53,4% (1 lần) xuống 22,4% (> 10 lần)	Tiết kiệm chi phí, tránh làm phiền khách
Cân đối lại nguồn lực theo tháng, không dồn quá nhiều cuộc gọi vào tháng 5	H6: tháng 5 chiếm 25,3% cuộc gọi nhưng chỉ 32,8% đăng ký	Tăng hiệu quả trên mỗi cuộc gọi
Ưu tiên khách không vay nhà và nhóm khách lớn tuổi, student, retired	H5, H1, H2	Tập trung vào nhóm có xác suất cao
Ưu tiên liên lạc qua điện thoại di động và làm rõ kênh liên hệ chưa xác định	H7: cellular 54,3% so với unknown 22,6%	Tiếp cận hiệu quả hơn

4.3. Giới hạn của tập dữ liệu

- Dữ liệu của **một ngân hàng**, không có thông tin thu nhập, chi phí cuộc gọi, ngày/năm cụ thể (không đánh giá được xu hướng theo thời gian dài).
- `duration` **chỉ biết sau cuộc gọi**, nên không thể dùng để dự đoán trước khi gọi.
- `unknown` rất cao ở `poutcome` (74,59%) và `contact` (21,02%); điền Mode ở `job`/`education` có thể làm lệch nhẹ.

- Tháng 5 chiếm 25,3% cuộc gọi, các tháng khác rất ít dữ liệu (mar, sep, oct, dec) nên tỷ lệ theo tháng kém ổn định.
- Phân tích chỉ chứng minh **mối liên hệ**, chưa chứng minh **nhân quả**.

4.4. Hướng mở rộng

- Xây **mô hình dự đoán** (Logistic Regression, Random Forest) **không dùng `duration`**, dùng `df_processed` đã chuẩn bị ở Giai đoạn 2.
- Thu thêm dữ liệu: thu nhập, nhiều ngân hàng, nhiều năm; thử **A/B testing** cho ngưỡng số lần gọi và hình thức liên hệ.

TÀI LIỆU THAM KHẢO

[1] Kaggle, *Bank Marketing Dataset* (janiobachmann): https://www.kaggle.com/datasets/janiobachmann/bank-marketing-dataset

[2] Mã nguồn và dữ liệu của nhóm trên GitHub: https://github.com/nahaaig/KHDL-Nhom16-PRJ2

[3] Tài liệu hướng dẫn và đề bài Mid-term 2 của giảng viên.